

Lista de Exercícios: Google SRE (Site Reliability Engineering)

Instruções: Responda às questões abaixo apresentando os cálculos e fundamentações necessárias.

1. Explique o conceito da “Muralha da Confusão” (*Wall of Confusion*) existente no modelo tradicional de TI entre as equipes de Desenvolvimento e Operações (Sysadmins). Como o modelo SRE criado por Ben Treynor Sloss no Google resolve essa incompatibilidade de incentivos utilizando a Engenharia de Software?

2. De acordo com os princípios de Engenharia de Confiabilidade do Google, qual é a porcentagem máxima recomendada de tempo que um engenheiro SRE deve gastar em atividades operacionais manuais e repetitivas (*Toil*), e qual deve ser o destino do tempo restante?

- a) No máximo 30% em *Toil*; os 70% restantes devem ser dedicados a plantões adicionais.
- b) No máximo 50% em *Toil*; os 50% restantes devem ser dedicados a projetos de engenharia de software e automação.
- c) No máximo 75% em *Toil*; os 25% restantes devem ser dedicados a atendimento de tickets de suporte de nível 1.
- d) No máximo 10% em *Toil*; os 90% restantes devem ser dedicados ao desenvolvimento de novas funcionalidades do produto.
- e) 100% do tempo em *Toil*; equipes de SRE não devem escrever código de automação.

3. Um serviço web de grande porte possui um Objetivo de Nível de Serviço (SLO) de disponibilidade estipulado em **99,9%** para um mês comercial de 30 dias (720 horas).

- a) Calcule o percentual do *Error Budget* e o tempo máximo total de indisponibilidade (*downtime*) permitido no mês, em minutos.

- b) Se a diretoria decidir elevar o SLO para **99,99%**, qual será o novo tempo máximo de *downtime* mensal permitido? Discuta por que buscar 100% de disponibilidade é financeiramente e operacionalmente inviável.

4. No modelo Google SRE, estima-se que cada incidente grave exige aproximadamente 6 horas de trabalho total (mitigação, investigação, escrita de postmortem e automação). Com base nisso, qual é o limite máximo sustentável de incidentes graves por turno de 12 horas?

- a) No máximo 1 incidente por turno.
- b) No máximo 2 incidentes por turno.
- c) No máximo 5 incidentes por turno.
- d) No máximo 8 incidentes por turno.
- e) Não há limite, desde que o plantonista permaneça acordado.

5. Uma equipe composta por 4 engenheiros SRE soma 160 horas semanais de trabalho útil. Na medição do último mês, verificou-se que 112 horas semanais foram gastas respondendo a alertas manuais, executando rotinas repetitivas de manutenção e atendendo tickets de suporte.

- a) Calcule o percentual de tempo gasto pela equipe em *Toil* (trabalho operacional braçal).
- b) O limite máximo recomendado pela filosofia SRE foi ultrapassado? Caso positivo, qual mecanismo institucional de proteção o modelo SRE exige que seja acionado?

6. O *Error Budget* (Orçamento de Erro) é um conceito central em SRE definido como 100% – SLO. O que deve acontecer quando uma equipe de produto esgota 100% do seu *Error Budget* em um determinado ciclo?

- a) A equipe de SRE deve ser responsabilizada financeiramente e pagar multas operacionais.
- b) O SLO do sistema deve ser automaticamente reduzido para cobrir as falhas ocorridas.
- c) O congelamento de deploys de novas funcionalidades (*feature releases*) deve ser acionado, priorizando a estabilização e correção de bugs de infraestrutura.
- d) O limite de indisponibilidade é zerado automaticamente sem necessidade de ação corretiva.
- e) Os clientes devem receber reembolso imediato, independentemente dos termos do SLA contratual.

7. Durante um deploy manual realizado na sexta-feira às 19h, um desenvolvedor executou um script de migração de banco de dados no ambiente errado, resultando na perda de dados de transações e em 2 horas de paralisação.

- a) Por que a abordagem tradicional de culpar ou demitir o profissional é considerada prejudicial para a confiabilidade de longo prazo no modelo SRE?
- b) Sob a perspectiva de um *Postmortem Blameless* (Sem Culpados), cite dois elementos fundamentais que devem constar no documento e proponha uma melhoria de engenharia para evitar que a falha humana volte a derrubar o sistema.

8. Assinale a alternativa que descreve CORRETAMENTE a relação de rigor e hierarquia entre SLI (Indicador), SLO (Objetivo) e SLA (Acordo):

- a) O SLA contratual deve ser mais rigoroso e exigente do que o SLO interno da equipe técnica.
- b) O SLI mede a meta desejada, enquanto o SLO é a cláusula jurídica de penalidade financeira.
- c) O SLO é a meta interna de confiabilidade adotada pela equipe de engenharia e deve ser igual ou mais estrito que o SLA acordado com os clientes.
- d) O SLA não possui implicações comerciais nem financeiras em caso de descumprimento.
- e) O SLI representa a porcentagem de chamados telefônicos atendidos pelo suporte técnico.

9. Considere os seguintes indicadores de uma API de pagamento:

- **SLI:** Porcentagem de requisições HTTP com resposta com código 200 OK em tempo < 300ms.
- **SLO:** 99,5% das requisições atendendo ao critério acima em um período de 24 horas.
- **SLA:** 99,0% de requisições atendidas, sob pena de reembolso financeiro de 10% na fatura dos clientes.

Em um dia de pico com 2.000.000 de requisições totais, 16.000 requisições demoraram mais de 300ms ou retornaram erro 500.

- a) O SLI medido no dia atendeu ao SLO? Apresente os cálculos.
- b) O SLA foi violado a ponto de gerar penalidade financeira para a empresa? Justifique.

10. Qual é a finalidade principal de confeccionar um relatório de *Postmortem Blameless* (Análise Pós-Incidente Sem Culpados) após a ocorrência de uma falha grave em produção?

- a) Identificar e punir disciplinarmente o desenvolvedor ou operador que cometeu o erro manual.
- b) Provar judicialmente que a equipe de infraestrutura não teve culpa na interrupção do serviço.
- c) Identificar falhas nos processos, ferramentas e arquitetura do sistema para implementar automações e proteções que impeçam a repetição da falha.
- d) Isentar a empresa do cumprimento de acordos de nível de serviço (SLAs) com os clientes.
- e) Justificar o aumento do orçamento financeiro do departamento de TI.

11. A famosa frase de Ben Treynor afirma: “*SRE é o que acontece quando você pede a um engenheiro de software para projetar uma equipe de operações*”. Diferencie os conceitos de DevOps e SRE em termos de escopo e implementação. Como a SRE concretiza na prática o princípio DevOps de “Automação de Tudo”?

12. O modelo SRE estima que cada incidente grave exige cerca de 6 horas de trabalho dedicado (mitigação, investigação de causa-raiz, escrita de postmortem e implementação de automação preventiva).

- a) Em um turno de plantão (*on-call*) de 12 horas, qual é a quantidade máxima sustentável de incidentes por turno?
- b) Caso um plantonista receba 5 alertas urgentes em um único turno de 12 horas, explique as consequências imediatas para a qualidade das respostas técnicas e para a saúde da equipe (*burnout* e fadiga de alertas).

13. Uma equipe de produto esgotou 100% do seu *Error Budget* trimestral logo nos primeiros 15 dias do trimestre devido a falhas recorrentes de um novo módulo.

- a) De acordo com os princípios do Google SRE, qual deve ser a ação imediata aplicada ao pipeline de novos lançamentos (*feature releases*) da equipe de Desenvolvimento?
- b) Como o *Error Budget* funciona como um mecanismo neutro de negociação entre a velocidade de inovação (Dev) e a estabilidade de produção (SRE)?

14. Em um quadro Kanban de uma equipe SRE, o trabalho é dividido entre tarefas de Operação (atendimento a chamados/resposta a incidentes) e projetos de Engenharia (automação/desenvolvimento de ferramentas). Explique como a distribuição de cartões no Kanban deve se comportar em um **Sistema Maduro** vs. um **Sistema Instável (Com Alto Débito Técnico)**.

15. O modelo Google SRE define uma diretriz clara: “O Pager só deve tocar quando um ser humano precisa tomar uma ação imediata em produção”.

- a) Diferencie a destinação adequada de um **Alerta Urgente (Pager)**, um **Alerta Informativo (Ticket/Email)** e um **Registro de Log**.
- b) Suponha que o uso de CPU de um servidor secundário atingiu 85%, mas o sistema continua respondendo normalmente sem impacto aos usuários. Esse evento deve acionar o pager? Justifique sua resposta com base nos princípios SRE.

16. Uma API de transações bancárias opera 24/7 com um SLO de disponibilidade fixado em **99,95%** para um mês comercial de 30 dias (720 horas).

- a) Calcule o orçamento total de erros (*Error Budget*) em minutos para todo o mês.
- b) Na primeira semana (7 dias completos), ocorreu uma instabilidade que causou 12,6 minutos de indisponibilidade acumulada. Calcule a porcentagem do *Error Budget* mensal

que foi consumida nessa primeira semana e analise se a taxa de queima (*Burn Rate*) excedeu o limite proporcional esperado para 7 dias ($\approx 23,3\%$ do mês).

17. Uma plataforma de streaming mede seu SLI de latência estabelecendo que a busca de vídeos deve responder em tempo $< 150\text{ms}$. O SLO estipulado é de **99,8%** de requisições bem-sucedidas dentro desta meta de tempo por dia. Em um dia de pico com 5.000.000 de requisições totais:

- 4.985.000 requisições responderam em $< 150\text{ms}$.
 - 15.000 requisições levaram entre 150ms e 500ms.
- a) Calcule a porcentagem real do SLI de latência atingida no dia e determine se a equipe cumpriu ou violou o SLO.
- b) Calcule quantas requisições lentas a mais poderiam ter ocorrido no dia antes de o SLO de 99,8% ser estourado.

“Boa atividade! Att. Me. Prof. Sergio Souza Novak.”